

Análisis de componentes principales

Emilio Carrizosa

Sevilla, 9 de marzo de 2023

Análisis de componentes principales

LIII. *On Lines and Planes of Closest Fit to Systems of Points in Space.* By KARL PEARSON, F.R.S., University College, London*.


(1) **I**N many physical, statistical, and biological investigations it is desirable to represent a system of points in plane, three, or higher dimensioned space by the "best-fitting" straight line or plane. Analytically this consists in taking

$$y = a_0 + a_1x, \quad \text{or} \quad z = a_0 + a_1x + b_1y,$$

$$\text{or} \quad z = a_0 + a_1x_1 + a_2x_2 + a_3x_3 + \dots + a_nx_n,$$

where $y, x, z, x_1, x_2, \dots, x_n$ are variables, and determining the "best" values for the constants $a_0, a_1, b_1, a_0, a_1, a_2, a_3, \dots, a_n$ in relation to the observed corresponding values of the variables. In nearly all the cases dealt with in the text-books

(y' being the ordinate of the theoretical line at the point x which corresponds to y), had we wanted to determine the best-fitting line in the usual manner.



Geometría euclídea básica

Sea $c \in \mathbb{R}^p$, $c^\top c = 1$

- Para $x \in \mathbb{R}^p$, la proyección $\pi_c(x)$ de x en la recta $\{tc : t \in \mathbb{R}\}$: resolviendo

$$\min_t \|x - tc\|_2^2$$

- $$t^2 \cdot 1 + \|x\|^2 - 2tc^\top x \xrightarrow{\frac{d}{dt}=0} 2t - 2c^\top x = 0 \Rightarrow t^* = c^\top x$$

$$\pi_c(x) = (c^\top x)c$$

$$\|x - \pi_c(x)\|_2^2 = \|x\|_2^2 + (c^\top x)^2 \|c\|_2^2 - 2x^\top (c^\top x) c = \|x\|_2^2 - (c^\top x)^2$$

- Sea X un vector aleatorio en \mathbb{R}^p con $E(X) = 0$

$$E(\|X - \pi_c(X)\|_2^2) = E(\|X\|_2^2) - E((c^\top X)^2) = E(\|X\|_2^2) - \text{var}(c^\top X)$$

$$E(\|X\|^2) - [\text{var}(c^\top X) + E^2(c^\top X)]$$

Primera componente principal

slide anterior

$$\min_{\text{s.a. } c^T c = 1} E(\|X - \pi_c(X)\|_2^2) = \min_{\text{s.a. } c^T c = 1} [E(\|X\|_2^2) - \text{var}(c^T X)]$$

↓
sin c

- min = max

$$\max_{\text{s.a. } c^T c = 1} \text{var}(c^T X)$$

$$\begin{aligned} \text{var}(c^T X) &= c^T \text{var}(X) c = \\ &= c^T [E(XX^T) - E(X)E(X)^T] c \end{aligned}$$

Hemos supuesto
esto

$$\Sigma = \text{var}(X) = E(XX^T) - E(X)E(X)^T$$

↑
0

$$\max_{\text{s.a. } c^T c = 1} c^T \Sigma c$$

Primera componente principal

$$\begin{array}{ll} \max & c^\top \Sigma c \\ \text{s.a} & c^\top c = 1 \end{array} \quad \Sigma \text{ semidef. pos.}$$

- Problema de maximización cuadrática convexa con restricciones no lineales
- KKT:

- $\mathcal{L}(c, \lambda) = c^\top \Sigma c - \lambda(c^\top c - 1)$
- $\nabla_c \mathcal{L} = 0 : \Sigma c = \lambda c$
 - λ : autovalor de Σ
 - c : autovector unitario asociado
 - $c^\top \Sigma c = \lambda c^\top c = \lambda$

•

$$\begin{array}{ll} \max & \lambda \\ \text{s.a} & \Sigma c = \lambda c \\ & c^\top c = 1 \end{array} \quad \begin{array}{l} \text{función objetivo} \\ \text{en el óptimo:} \\ c^\top \Sigma c = c^\top \lambda c = \lambda \end{array}$$

- Solución óptima: c : autovector unitario, asociado al **mayor** autovalor λ_1 de Σ
- c : **Primera componente principal**

Primera componente principal

Bondad de ajuste. Varianza explicada

- Sea c^1 : primera componente principal, asociada al mayor autovalor (λ_1) de Σ
 $E[\sum_i x_i^2] = \sum_i E[x_i^2] = \sum_i \sigma_i^2 = tr(\Sigma)$
- $E(\|X - \pi_{c^1}(X)\|_2^2) = E(\|X\|_2^2) - var(c^\top X) = tr(\Sigma) - \lambda_1$
Sol óptima
- $\frac{E(\|X - \pi_{c^1}(X)\|_2^2)}{E(\|X\|_2^2)} = 1 - \frac{\lambda_1}{\sum_{j=1}^p \lambda_j}$
 $c^\top \Sigma c = c^\top \lambda c = c^\top c \lambda = \lambda$
- $\frac{\lambda_1}{\sum_{j=1}^p \lambda_j}$: fracción de varianza explicada por la primera componente principal

k componentes principales

Construidas las j primeras componentes principales, c^1, \dots, c^j , la componente principal $j+1$ es la solución óptima del problema de encontrar el vector unitario c , ortogonal a c^1, \dots, c^j , que maximice la varianza de la proyección $c^\top X$:

$$\begin{aligned} \max \quad & c^\top \Sigma c \\ & c^\top c^i = 0 \quad i = 1, 2, \dots, j \\ & c^\top c = 1 \end{aligned}$$

La componente principal j ($1 \leq j \leq n$) es el autovector unitario asociado al j -ésimo mayor autovalor de Σ

Nunca hay solución única: por ejemplo, si c^j es componente principal, también lo sería $-c^j$. Abusaremos del lenguaje

Las **puntuaciones** $(c^i)^\top X, (c^j)^\top X$: incorreladas: $\text{cov}((c^i)^\top X, (c^j)^\top X) = E((c^i)^\top X)((c^j)^\top X)) = E((c^i)^\top X)(X^\top c^j)) = \lambda_j E((c^i)^\top c_j) = 0$

Bondad de ajuste. Varianza explicada

Para cada k , $1 \leq k \leq p$,

- las componentes principales c^1, \dots, c^k son una base ortonormal del espacio V de dimensión k que minimiza la esperanza del cuadrado de la distancia euclídea entre X y su proyección $\pi_V(X)$ sobre V
- $\frac{E(\|X - \pi_V(X)\|_2^2)}{E(\|X\|_2^2)} = 1 - \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j}$
- $\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j}$: fracción de varianza explicada por las k primeras componentes principales


$\bar{X} \rightsquigarrow (c^1' \bar{X}, \dots, c^p' \bar{X})$ coordenadas de \bar{X} con base formada por componentes principales

$\bar{X} \rightsquigarrow (c^1' \bar{X}, \dots, c^p' \bar{X})$ (puntuaciones scores)

$$\text{para } i \neq j \text{ cov}(c^i' \bar{X}, c^j' \bar{X}) = E[(c^i' \bar{X} - E(c^i' \bar{X}))(c^j' \bar{X} - E(c^j' \bar{X}))] = \\ = E[c^i' \bar{X} c^j' \bar{X}] = E[c^i' \bar{X} \bar{X}' c^j]$$

El problema de selección del k

- Tomar $k = p$ componentes principales: cambio de sistema de referencia ortonormal
- Cuanto mayor k , mayor varianza explicada (= menor error al reemplazar X por $\pi(X)$), pero peor interpretabilidad de resultados



• Criterios:


- Seleccionar k tal que se explique al menos una fracción de varianza (por ejemplo, el 80%)
- Seleccionar k tal que la varianza explicada dé el mayor salto al pasar de k a $k + 1$
- ...

El problema de la escala

- Un cambio de escala (AX en lugar de X) hace que cambien las componentes principales: autovectores de $A\Sigma A^\top$ y no de Σ
- Aplicar análisis de componentes principales a AX es lo mismo que aplicarlo a X , pero tomando, en vez de la matriz de covarianzas Σ , la matriz $A\Sigma A^\top$.
- En particular, podemos hacer análisis de componentes principales
 - con la matriz de covarianzas
 - con la matriz de correlaciones

Componentes principales muestrales

Tenemos $x_1, \dots, x_n \in \mathbb{R}^p$, que entendemos realizaciones de un vector aleatorio X en \mathbb{R}^p .




- Las componentes principales c^1, \dots, c^k son una base ortonormal del espacio V de dimensión k que minimiza la media del cuadrado de la distancia euclídea entre los x_i y su proyección $\pi_V(x_i)$ sobre V
- Se corresponden con los autovectores unitarios asociados a los k mayores autovalores λ_j de la matriz de covarianzas muestrales
- $\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j}$: fracción de varianza explicada por las k primeras componentes principales

Análisis en componentes principales no lineales. KPCA

Un ejemplo


- $x_1, \dots, x_{n_1+n_2} \in \mathbb{R}^{30}$
- $x_i = (10 \cos(\theta_i) + \varepsilon_{i1}, 10 \sin(\theta_i) + \varepsilon_{i2}, \varepsilon_{i3}, \dots, \varepsilon_{i30}), i = 1, \dots, n_1 = 100$
- $x_i = (15 \cos \theta_i + \varepsilon_{i1}, 15 \sin \theta_i + \varepsilon_{i2}, \varepsilon_{i3}, \dots, \varepsilon_{i30}),$
 $i = n_1 + 1, \dots, n_1 + n_2 = 400$
- $\theta_i \sim \mathcal{U}(0, 2\pi), \varepsilon_{ij} \sim \mathcal{N}(0, 1), i = 1, \dots, n_1 + n_2, j = 1, \dots, 30$



Análisis en componentes principales no lineales. KPCA

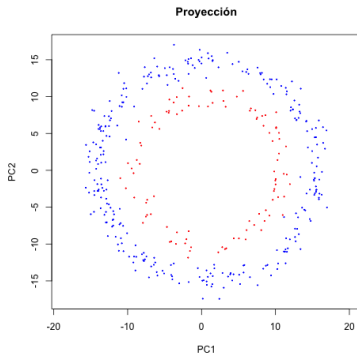
Un ejemplo

- $x_1, \dots, x_{n_1+n_2} \in \mathbb{R}^{30}$
- $x_i = (10 \cos(\theta_i) + \varepsilon_{i1}, 10 \sin(\theta_i) + \varepsilon_{i2}, \varepsilon_{i3}, \dots, \varepsilon_{i30}), i = 1, \dots, n_1 = 100$
- $x_i = (15 \cos \theta_i + \varepsilon_{i1}, 15 \sin \theta_i + \varepsilon_{i2}, \varepsilon_{i3}, \dots, \varepsilon_{i30}),$
 $i = n_1 + 1, \dots, n_1 + n_2 = 400$
- $\theta_i \sim \mathcal{U}(0, 2\pi), \varepsilon_{ij} \sim \mathcal{N}(0, 1), i = 1, \dots, n_1 + n_2, j = 1, \dots, 30$



PCA:


- Fracción de varianza explicada: 0.465 0.873 0.880 0.887 0.893 0.900, 0.906 0.911 0.917 0.922 0.927 0.933 0.938 0.942 ...



Análisis en componentes principales no lineales. KPCA


Un ejemplo

- $x_1, \dots, x_{n_1+n_2} \in \mathbb{R}^{31}$
- $x_i = (10 \cos(\theta_i) + \varepsilon_{i1}, 10 \sin(\theta_i) + \varepsilon_{i2}, \varepsilon_{i3}, \dots, \varepsilon_{i30}, x_{i1}^2 + x_{i2}^2),$
 $i = 1, \dots, n_1 = 100$
- $x_i = (15 \cos \theta_i + \varepsilon_{i1}, 15 \sin \theta_i + \varepsilon_{i2}, \varepsilon_{i3}, \dots, \varepsilon_{i30}, x_{i1}^2 + x_{i2}^2),$
 $i = n_1 + 1, \dots, n_1 + n_2 = 400$
- $\theta_i \sim \mathcal{U}(0, 2\pi), \varepsilon_{ij} \sim \mathcal{N}(0, 1), i = 1, \dots, n_1 + n_2, j = 1, \dots, 30$
- Fracción de varianza explicada: 0.940 0.968 0.992 0.993 ...




PCA en \mathbb{R}^{30}

Proyección



PCA en \mathbb{R}^{31}

Proyección



- Podemos hacer el PCA tras una **inmersión** de los datos $x_1, \dots, x_n \in \mathbb{R}^p$ con una función ϕ
- Los datos deben estar centrados:

$$\{x_1, \dots, x_n\} \mapsto \left\{ \phi(x_1) - \frac{1}{n} \sum_{i=1}^n \phi(x_i), \dots, \phi(x_n) - \frac{1}{n} \sum_{i=1}^n \phi(x_i) \right\}$$

- Componentes principales: autovectores de

$$\left(\phi(x_1) - \frac{1}{n} \sum_{i=1}^n \phi(x_i), \dots, \phi(x_n) - \frac{1}{n} \sum_{i=1}^n \phi(x_i) \right) \left(\phi(x_1) - \frac{1}{n} \sum_{i=1}^n \phi(x_i), \dots, \phi(x_n) - \frac{1}{n} \sum_{i=1}^n \phi(x_i) \right)^\top$$

- Sean $\Phi = (\phi(x_1), \dots, \phi(x_n))$, $E = \begin{pmatrix} 1 & 1 & \dots & 1 \\ \vdots & & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{pmatrix}$. Las componentes

principales: autovectores de

*No será \sum
sino $\hat{\sum} = S_{\text{mod}}$*

$$\left(\Phi - \Phi \frac{1}{n} E \right) \left(\Phi - \Phi \frac{1}{n} E \right)^\top = \Phi \left(I - \frac{1}{n} E \right)^2 \Phi^\top$$

- Sea u : componente principal, esto es: autovector unitario de $\Phi \left(I - \frac{1}{n} E \right)^2 \Phi^\top$. Entonces

$$\Phi \left(I - \frac{1}{n} E \right)^2 \Phi^\top u = \lambda u$$

- $u = \underbrace{\Phi \frac{1}{\lambda} \left(I - \frac{1}{n} E \right)^2 \Phi^\top u}_\omega$

- $u = \sum_{i=1}^n \omega_i \phi(x_i)$

- La puntuación de un cierto x :

$$u^\top \left(\phi(x) - \frac{1}{n} \sum_{j=1}^n \phi(x_j) \right) = \sum_{i=1}^n \omega_i \phi(x_i)^\top \phi(x) - \frac{1}{n} \sum_{i,j=1}^n \omega_i \phi(x_i)^\top \phi(x_j)$$

$$\sum_i \omega_i \phi(x_i) \left[\phi(x) - \frac{1}{n} \sum_j \phi(x_j) \right]$$

$$u^\top \left(\phi(x) - \frac{1}{n} \sum_{j=1}^n \phi(x_j) \right) = \sum_{i=1}^n \omega_i \phi(x_i)^\top \phi(x) - \frac{1}{n} \sum_{i,j=1}^n \omega_i \phi(x_i)^\top \phi(x_j)$$

$$u^\top \left(\phi(x) - \frac{1}{n} \sum_{j=1}^n \phi(x_j) \right) = \sum_{i=1}^n \omega_i \phi(x_i)^\top \phi(x) - \frac{1}{n} \sum_{i,j=1}^n \omega_i \phi(x_i)^\top \phi(x_j)$$

No necesitamos conocer ϕ . Solo necesitamos conocer la función **núcleo (kernel)**
 $K : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$, $K(x, z) = \phi(x)^\top \phi(z)$

$$u^\top \left(\phi(x) - \frac{1}{n} \sum_{j=1}^n \phi(x_j) \right) = \sum_{i=1}^n \omega_i \phi(x_i)^\top \phi(x) - \frac{1}{n} \sum_{i,j=1}^n \omega_i \phi(x_i)^\top \phi(x_j)$$

No necesitamos conocer ϕ . Solo necesitamos conocer la función **núcleo (kernel)**
 $K : \mathbb{R}^p \times \mathbb{R}^p \longrightarrow \mathbb{R}$, $K(x, z) = \phi(x)^\top \phi(z)$

Puntuación de x según componente principal:

$$u^\top \left(\phi(x) - \frac{1}{n} \sum_{j=1}^n \phi(x_j) \right) = \sum_{i=1}^n \omega_i K(x_i, x) - \frac{1}{n} \sum_{i,j=1}^n \omega_i K(x_i, x_j)$$

Posibles núcleos K :

- $K(x, z) = x^\top z$ (lineal)
- $K(x, z) = (1 + x^\top z)^d$ (polinómico)
- $K(x, z) = \exp(-\gamma \|x - z\|_2^2)$ (gaussiano; RBF)
- ...

- Para evaluar las puntuaciones no necesitamos ϕ , sino K . Pero para eso necesitamos calcular los autovectores de $\Phi \left(I - \frac{1}{n}E\right) \left(I - \frac{1}{n}E\right)^\top \Phi^\top$
- Si z es autovector de $M^\top M$ con autovalor $\lambda \neq 0$, entonces Mz es autovector de MM^\top con autovalor λ
- Si z es autovector de $\left(I - \frac{1}{n}E\right)^\top \Phi^\top \Phi \left(I - \frac{1}{n}E\right)$ para un autovalor $\lambda > 0$, entonces $\Phi \left(I - \frac{1}{n}E\right) z$ es (salvo normalización) componente principal con autovalor λ .
- $\Phi^\top \Phi = \begin{pmatrix} K(x_1, x_1) & \cdots & K(x_1, x_n) \\ \vdots & \ddots & \vdots \\ K(x_n, x_1) & \cdots & K(x_n, x_n) \end{pmatrix}$